FACULDADE DE CIÊNCIAS HUMANAS E SOCIAIS – FACIHUS
CENTRO UNIVERSITÁRIO MÁRIO PALMÉRIO – UNIFUCAMP
CURSO DE BACHARELADO EM CIÊNCIAS DA COMPUTAÇÃO.

LUCAS FIRMINO RODRIGUES

CARLOS EDUARDO MENDES

DA ELIZA AOS TRANSFORMERS: A EVOLUÇÃO DO PROCESSAMENTO DE LINGUAGEM NATURAL

MONTE CARMELO – MG

MARÇO DE 2026

LUCAS FIRMINO RODRIGUES

CARLOS EDUARDO MENDES

DA ELIZA AOS TRANSFORMERS: A EVOLUÇÃO DO PROCESSAMENTO DE LINGUAGEM NATURAL

Relatório apresentado à disciplina de Inteligência Artificial do curso de Ciências da Computação do Centro Universitário Mário Palmério, sob orientação do Prof. Gustavo Henrique Ribeiro Magalhães.

MONTE CARMELO – MG

MARÇO DE 2026

SUMÁRIO

1. INTRODUÇÃO 3
2. DESENVOLVIMENTO 4
3. COMPARATIVO DE ABORDAGENS 6
4. CONCLUSÃO: IMPACTO DO RLHF 7
5. REPOSITÓRIO GITHUB 8
6. REFERÊNCIAS 8

1. INTRODUÇÃO

Este relatório documenta a jornada de aprendizado sobre a evolução do Processamento de Linguagem Natural (PLN), estruturada em três fases ao longo de 15 dias. O objetivo central da atividade foi compreender a transição histórica de sistemas baseados em regras rígidas e simbólicas para os modernos modelos neurais baseados em atenção, implementando e analisando cada abordagem por meio de scripts desenvolvidos em linguagem Python.

A evolução do PLN representa uma das trajetórias mais fascinantes da Inteligência Artificial. Desde a ELIZA, criada em 1966, que simulava conversas por meio de simples substituições de padrões, até os Transformers, que em 2017 revolucionaram a forma como máquinas compreendem e geram linguagem, cada geração de tecnologia resolveu limitações de sua predecessora ao custo de maior complexidade computacional.

A análise comparativa entre as abordagens revela como a capacidade dos sistemas de "entender" linguagem evoluiu drasticamente, evidenciando as implicações práticas de cada paradigma no contexto das aplicações de inteligência artificial contemporâneas.

2. DESENVOLVIMENTO

2.1 Fase 1: A Era Simbólica — O Chatbot ELIZA

A primeira fase consistiu na implementação de um chatbot inspirado na ELIZA (Weizenbaum, 1966), um dos primeiros programas de processamento de linguagem natural da história. O sistema foi desenvolvido no arquivo fase1_eliza.py e utiliza Expressões Regulares (Regex) para identificar padrões na entrada do usuário, mapeando-os para respostas pré-programadas.

Funcionamento: o script percorre uma lista ordenada de padrões Regex. Ao encontrar o primeiro padrão que corresponde à entrada do usuário, seleciona aleatoriamente uma resposta da lista associada a esse padrão. Caso nenhum padrão seja identificado, o sistema retorna uma resposta genérica. O programa encerra quando o usuário digita palavras como "sair" ou "tchau".

A reflexão central desta fase diz respeito aos motivos pelos quais o sistema falha com frases fora do roteiro. A ELIZA apresenta limitações estruturais fundamentais: rigidez total, pois apenas frases que correspondem exatamente aos padrões definidos recebem respostas relevantes; ausência de memória de contexto, já que cada mensagem é processada de forma completamente isolada; e ausência de compreensão semântica, uma vez que o sistema não "entende" o significado das palavras, apenas reconhece padrões de caracteres.

Um exemplo ilustrativo dessa limitação é que a frase "Estou triste" pode ser reconhecida pelo sistema, enquanto "Ando meio pra baixo", com significado equivalente, não é processada corretamente, pois as palavras diferem dos padrões cadastrados. Essa fragilidade caracteriza a principal deficiência da Era Simbólica do PLN.

2.2 Fase 2: A Revolução Estatística — N-Grams

A segunda fase representou uma ruptura paradigmática: o abandono das regras fixas em favor da probabilidade estatística. O script fase2_ngramas.py implementa modelos de bigramas e trigramas que aprendem, a partir de um corpus de texto em português, a frequência com que palavras co-ocorrem em sequência.

Conceito de N-Gram: um modelo de N-Grams calcula a probabilidade condicional de uma palavra dado um contexto de N-1 palavras anteriores. O bigrama utiliza apenas a palavra imediatamente anterior como contexto, enquanto a trigrama considera as duas palavras precedentes. A predição da próxima palavra é realizada por amostragem ponderada com base nessas probabilidades.

Durante os testes, foram observadas distribuições de probabilidade como a do contexto "o gato", no qual as palavras "miou", "correu", "bebeu" e "assustado" apresentaram probabilidades iguais de 25% cada, refletindo o corpus reduzido utilizado. Em corpora maiores, como a Wikipedia, a distribuição seria muito mais concentrada nas palavras mais frequentes.

O exemplo mais ilustrativo da limitação desta abordagem foi gerado com a semente "flor": o texto produzido foi "flor desabrochou na janela o sorvete gelado o sol brilhou forte durante as". A incoerência ocorre porque o bigrama esquece o contexto inicial após cada passo. Ao prever a palavra seguinte à "na", o modelo não sabe mais que a semente foi "flor" — apenas

que "na" precede "janela" no corpus, oriundo da frase original "O gato miou alto na janela". O texto deriva completamente para outro assunto.

Bigramas produzem textos divagantes ao perder o contexto rapidamente, enquanto trigramas tendem a ser mais coerentes no início, porém podem ficar presos em loops ao repetir sequências inteiras do corpus. Essa limitação da memória curta impede a geração de textos coerentes e longos, evidenciando a necessidade de modelos com contexto mais amplo.

2.3 Fase 3: Transformers e Atenção

A terceira e última fase apresentou a revolução de 2017, introduzida pelo artigo "Attention is All You Need" (Vaswani et al., 2017), que propôs a arquitetura Transformer como substituta às Redes Neurais Recorrentes (RNNs). A atividade consistiu na utilização da biblioteca Hugging Face para executar os modelos GPT-2 e BERT em Python.

Self-Attention: o mecanismo central dos Transformers permite que o modelo aprenda, para cada token da sequência, quais outras partes são mais relevantes para interpretá-lo. Diferentemente das RNNs, que processam palavras sequencialmente, o Transformer visualiza a frase inteira de uma vez e calcula pesos de atenção entre todos os pares de tokens simultaneamente, possibilitando o processamento paralelo e a captura de dependências de longa distância.

GPT-2 (OpenAI, 2019) é um modelo auto-regressivo treinado para prever o próximo token, utilizado para geração de texto. BERT (Google, 2018) é um modelo bidirecional treinado para preencher tokens mascarados e classificar sequências, processando toda a frase simultaneamente. Ambos geram embeddings contextuais: a mesma palavra recebe representações vetoriais diferentes conforme o contexto em que aparece, resolvendo a ambiguidade semântica dos Word2Vec estáticos.

A principal vantagem desta abordagem é a capacidade de compreender o significado contextual das palavras. Na frase "O banco aprovou o empréstimo", o token "banco" recebe maior peso de atenção em relação a "empréstimo" e "aprovou", determinando seu sentido financeiro e não mobiliário. Esta distinção era impossível nas fases anteriores.

3. COMPARATIVO DE ABORDAGENS

A tabela a seguir sintetiza as principais características de cada abordagem estudada, permitindo visualizar a progressão das capacidades ao longo das fases:

Tabela 1 – Comparativo das abordagens de PLN estudadas

Atributo	ELIZA (Simbólica)	N-Grams (Estatística)	Transformers (Neural)
Lógica	Regex / Regras	Frequência / Probabilidade	Vetor / Atenção
Contexto	Nenhum	Curto (2–3 palavras)	Longo e Dinâmico
Flexibilidade	Rígida	Moderada	Extrema

A progressão é clara: cada geração resolveu as limitações da anterior ao custo de maior complexidade computacional e necessidade de dados de treinamento mais volumosos. A abordagem simbólica é determinística e interpretável, mas frágil. A estatística é adaptável ao corpus, mas carece de semântica. A neural é flexível e semântica, mas exige infraestrutura computacional robusta e grandes corpora.

4. CONCLUSÃO: IMPACTO DO RLHF

A realização desta atividade permitiu compreender, na prática, como a evolução do Processamento de Linguagem Natural foi marcada por mudanças paradigmáticas profundas. Cada fase superou as limitações da anterior: a abordagem estatística eliminou a rigidez simbólica; os embeddings introduziram semântica; os Transformers trouxeram contexto longo e processamento paralelo.

Contudo, os modelos Transformer base, como GPT-2 e BERT, ainda não constituem assistentes alinhados com necessidades humanas. Eles aprendem a estrutura da linguagem com maestria, mas sem valores, sem utilidade direcionada e sem critérios de segurança. É nesse contexto que o RLHF (Reinforcement Learning from Human Feedback — Aprendizado por Reforço com Feedback Humano) representa o avanço decisivo para a IA conversacional moderna.

O processo do RLHF ocorre em três etapas: (1) coleta de preferências humanas, na qual anotadores comparam respostas geradas pelo modelo e indicam qual é melhor segundo critérios de utilidade, segurança e honestidade; (2) treinamento de um modelo de recompensa,

que aprende a prever a preferência humana e atribui pontuação a cada resposta; e (3) ajuste fino por reforço, no qual o modelo de linguagem é otimizado por meio do algoritmo PPO (Proximal Policy Optimization) para maximizar as pontuações do modelo de recompensa, mantendo-se próximo ao comportamento original.

O RLHF é, portanto, a diferença entre um modelo que sabe gerar texto e um assistente que sabe como ajudar. Sistemas como ChatGPT, Claude e Gemini são Transformers base ajustados com RLHF — e é essa camada de alinhamento que determina se o modelo responde de forma adequada a uma pergunta médica, se recusa a gerar conteúdo prejudicial e se mantém uma conversa coerente e consistente ao longo das interações. Sem RLHF, os modelos são fluentes, mas desalinhados; com RLHF, tornam-se ferramentas úteis, seguras e confiáveis.

De modo geral, o estudo permitiu perceber as diferenças fundamentais entre as abordagens simbólica, estatística e neural, bem como o impacto do alinhamento na qualidade final dos sistemas de IA. A análise prática de cada método, por meio da implementação em Python, destacou a importância de se compreender não apenas o funcionamento dos modelos, mas também suas limitações e os avanços que cada paradigma representou para o campo do Processamento de Linguagem Natural.

5. REPOSITÓRIO GITHUB

https://github.com/lucasFR2/Eliza

6. REFERÊNCIAS

WEIZENBAUM, J. ELIZA — a computer program for the study of natural language communication between man and machine. Communications of the ACM, v. 9, n. 1, p. 36–45, 1966.

VASWANI, A. et al. Attention is All You Need. arXiv:1706.03762, 2017. Disponível em: https://arxiv.org/abs/1706.03762.

DEVLIN, J. et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv:1810.04805, 2018. Disponível em: https://arxiv.org/abs/1810.04805.

OUYANG, L. et al. Training language models to follow instructions with human feedback. arXiv:2203.02155, 2022. Disponível em: https://arxiv.org/abs/2203.02155.

HUGGING FACE. Transformers Library Documentation. 2024. Disponível em: https://huggingface.co/docs/transformers.